

Pima Indians Diabetes Veri Seti Detaylı Analiz Raporu

AWS AI & ML Scholars Programı — 2. Proje Çalışması Çıktıları

Hazırlayan: Meryem Küçük

Tarih: 12 Haziran 2026

Program Scope: AWS AI & ML Scholars (2. Proje Ödevi)

Kullanılan Modül: PartyRock Data Analysis Module

Özet

Bu analitik rapor, AWS AI & ML Scholars programı kapsamında üstlendiğim 2. Proje ödevi gereksinimlerini karşılamak amacıyla yapılandırılmıştır. Çalışmanın temel yürütücüsü ve odağı olarak, Amazon Bedrock altyapısı üzerinde çalışan bulut tabanlı PartyRock Data Analysis platformu kullanılmış ve tüm veri analitiği süreçleri bu modül vasıtasıyla yürütülmüştür. Proje süresince, tıp literatüründe kronik hastalıkların ve biyomedikal risk faktörlerinin incelenmesi için temel bir kaynak kabul edilen Pima Indians Diabetes veri kümesi ele alınmış ve tüm değişken katmanları bu modül aracılığıyla detaylıca taranmıştır. PartyRock veri analizi motorunun sunduğu fonksiyonel yetenekler kullanılarak, ham veri setinde yer alan 13 farklı veri katmanının her biri tek tek profil analizine tabi tutulmuş ve klinik özniteliklerin birbirleriyle olan ilişkileri incelenmiştir. Platformun veri analiz gücü sayesinde popülasyondaki eksik ya da tutarsız "0" (sıfır) değerleri tespit edilmiş, medyan imputasyon yaklaşımları kurgulanmış; glikoz, yaş, hamilelik ve BMI gibi kritik klinik eşiklerin diyabet teşhisi üzerindeki risk artışları tam şeffaflıkla gözlemlenmiştir. Ayrıca, programın temel taşlarından olan Sorumlu Yapay Zeka (Responsible AI) prensipleri doğrultusunda, veri kümesindeki alt yaş grupları ile sınıfsal dağılım dengesizlikleri titizlikle analiz edilerek veri setindeki yanlılık riskleri teorik zeminde değerlendirilmiştir. Sonuç olarak bu çalışma, bulut bilişim ve üretken yapay zeka tabanlı veri analitiği araçlarının hızlı veri keşfi süreçlerindeki kabiliyetlerini somut verilerle ortaya koyan müstakil bir 2. Proje raporu niteliğindedir.

Tablo 1: Genel Veri Seti Yapısı ve Değişken Tanımları

Değişken Adı	Veri Türü	Açıklama / Klinik Anlamı
Pregnancies	Sayısal (İnt)	Hamile kalma sayısı
Glucose	Sayısal (İnt)	Oral glikoz tolerans testindeki plazma glikoz konsantrasyonu
BloodPressure	Sayısal (İnt)	Diyastolik kan basıncı (mm Hg)
SkinThickness	Sayısal (İnt)	Triceps cilt kıvrım kalınlığı (mm)
Insulin	Sayısal (İnt)	2 saatlik serum insülini (mu U/ml)
BMI	Sayısal (Float)	Vücut Kitle İndeksi (kilo / boy^2)
DiabetesPedigreeFunction	Sayısal (Float)	Diyabet soy ağacı fonksiyonu (genetik skor)
Age	Sayısal (İnt)	Yaş
Outcome	Kategorik (0/1)	Diyabet durumu (0: Negatif, 1: Pozitif)

Tablo 1 Analizi: Veri setinin yapısal profili incelendiğinde, tamamı nümerik (sayısal) formatta olan 8 bağımsız klinik öznitelik ve ikili (binary) yapıdaki bir hedef değişkenden ("Outcome") oluştuğu görülmektedir. Verilerin bütünüyle sayısal yapıda yapılandırılmış olması, PartyRock veri analiz motorunun matematiksel dönüşümleri, istatistiksel segmentasyonları ve korelasyon analizlerini doğrudan, veri kaybı yaşamadan gerçekleştirmesini sağlamaktadır. Klinik açıdan bakıldığında değişkenler; metabolik, genetik ve demografik risk faktörlerini dengeli bir biçimde temsil etmektedir.

Tablo 2: Merkezi Eğilim ve Dağılım İstatistikleri

Öznitelik	Ortalama (Mean)	Medyan (Median)	Min Değer	Max Değer	Standart Sapma
Pregnancies	3.84	3.00	0.00	17.00	3.37
Glucose	120.89	117.00	0.00	199.00	31.97
BloodPressure	69.11	72.00	0.00	122.00	19.36
SkinThickness	20.54	23.00	0.00	99.00	15.95
Insulin	79.80	30.50	0.00	846.00	115.24
BMI	31.99	32.00	0.00	67.10	7.88
DiabetesPedigree	0.47	0.37	0.08	2.42	0.33
Age	33.24	29.00	21.00	81.00	11.76

Tablo 2 Analizi: Betimsel istatistik tablosu, verinin dağılım özellikleri hakkında kritik yapısal ipuçları vermektedir. Özellikle `Insulin` (Ort: 79.80, Medyan: 30.50) ve `SkinThickness` (Ort: 20.54, Medyan: 23.00) değişkenlerindeki ortalama ve medyan arasındaki belirgin sapma ile yüksek standart sapma değerleri, bu özniteliklerin sağa son derece çarpık bir dağılım sergilediğini ve uç değerler (outliers) barındırdığını kanıtlamaktadır. Diğer taraftan, yaş ortalamasının 33.24 ve medyanının 29 olması, genç-yetişkin bir popülasyon üzerinde çalışıldığını göstermektedir. En kritik bulgu ise; Glikoz, Kan Basıncı, Cilt Kalınlığı, İnsülin ve BMI gibi değişkenlerde minimum değer 0 olarak görünmesidir; bu durum tıbbi açıdan imkansız bir senaryodur.

Tablo 3: Eksik ve Hatalı Değer Analizi (Sıfır Değerleri Kontrolü)

Değişken Adı	Toplam Kayıt	Sıfır ("0") Sayısı	Hatalı/Eksik Oranı	Önerilen Müdahale
Glucose	768	5	%0.65	Medyan İmputasyonu
BloodPressure	768	35	%4.56	Medyan İmputasyonu
SkinThickness	768	227	%29.56	Sütun Dışlama veya Tahmin
Insulin	768	374	%48.70	Gelişmiş İmputasyon / Medyan
BMI	768	11	%1.43	Medyan İmputasyonu

Tablo 3 Analizi: Bu tablo, veri kümesindeki "gizli" eksik verilerin boyutunu gözler önüne sermektedir. Yaşayan bir insanda Glikoz, Kan Basıncı veya BMI değerinin 0 olması hayatla bağdaşmayacağı için, ham verideki bu sıfır değerleri aslında sisteme girilmemiş eksik verileri (NaN) temsil etmektedir. `Insulin` değişkeninde bu oran %48.70 gibi çok yüksek bir seviyededir; yani hastaların neredeyse yarısının insülin ölçümü eksiktir. `SkinThickness` ise %29.56 oranında eksiklik içermektedir. PartyRock ön işleme mekanizmalarında, bu eksikliklerin istatistiksel gücü bozmaması adına popülasyon medyanı ile ikame edilmesi (imputation) kararlaştırılmış, böylece satır kaybı engellenmiştir.

Tablo 4: Özniteliklerin Hedef Değişken (Outcome) ile Korelasyonu

Değişken	Korelasyon Katsayısı (r)	İlişki Derecesi	Yönü
Glucose	0.467	Orta-Güçlü	Pozitif
BMI	0.293	Zayıf-Orta	Pozitif
Age	0.238	Zayıf	Pozitif
Pregnancies	0.222	Zayıf	Pozitif
DiabetesPedigreeFunction	0.174	Çok Zayıf	Pozitif
Insulin	0.131	Çok Zayıf	Pozitif

Tablo 4 Analizi: Korelasyon analizi, diyabet hastalığının ortaya çıkışında en yüksek doğrusal korelasyona sahip tekil değişkenin **Glucose** ($r = 0.467$) olduğunu matematiksel olarak ortaya koymaktadır. Hücrelerin glikozu emememesi sonucu plazmada artan şeker miktarı teşhisin en birincil belirleyicisidir. İkinci en güçlü faktör ise obezite göstergesi olan **BMI** ($r = 0.293$) değişkenidir. Tablodaki tüm anlamlı ilişkilerin pozitif yönlü olması; klinik ölçüm değerleri, yaş veya gebelik sayısı arttıkça bireyin diyabet pozitif olma riskinin de doğrusal olarak yükseldiğini klinik teorilerle tam uyumlu şekilde doğrulamaktadır.

Tablo 5: Hamilelik Sayısı (Pregnancies) ve Diyabet Riski Dağılımı

Hamilelik Sayısı Grubu	Toplam Birey	Diyabet Pozitif (1)	Diyabet Oranı
0 - 2 Kez	338	72	%21.3
3 - 6 Kez	287	111	%38.6
7 ve Üzeri	143	84	%58.7

Tablo 5 Analizi: Gebelik sayısına göre yapılan gruplandırma analizi, kadın metabolizması üzerinde hamilelik döngülerinin kümülatif bir diyabetik risk oluşturduğunu göstermektedir. 0-2 kez hamilelik geçirmiş grupta diyabet prevalansı %21.3 iken, 7 ve daha fazla hamilelik geçiren kadınlarda bu oran %58.7'ye fırlayarak popülasyon çoğunluğunu oluşturmaktadır. Bu durum gestasyonel diyabet geçmişinin veya gebelik sürecindeki hormonal/metabolik değişimlerin kalıcı tip-2 diyabet riskini tetikleyen güçlü birer hızlandırıcı olduğunu göstermektedir.

Tablo 6: Glikoz Seviyesi Aralıklarına Göre Diyabet Dağılımı

Glikoz Skoru Aralığı	Toplam Birey	Diyabet Pozitif (1)	Diyabet Oranı
< 100 (Normal)	197	12	%6.1
100 - 139 (Sınırdı)	371	112	%30.2
140 ve Üzeri (Yüksek)	200	144	%72.0

Tablo 6 Analizi: Glikoz seviyelerinin klinik referans aralıklarına göre segmentasyonu, hastalığın teşhis sınırlarını net bir biçimde kanıtlamaktadır. Plazma glikoz değeri 100 mg/dL'nin altında olan grupta diyabet görülme oranı sadece %6.1 iken, Dünya Sağlık Örgütü'nün de kritik eşik kabul ettiği 140 mg/dL seviyesi aşıldığında bu oran dramatik bir sıçramayla %72.0'ye ulaşmaktadır. Bu bulgu, glikozun hedef değişken üzerindeki etkisinin doğrusal olmaktan ziyade, belirli bir kritik eşikten sonra katlanarak artan (logaritmik/adımsal) bir etkiye sahip olduğunu göstermektedir.

Tablo 7: Kan Basıncı (BloodPressure) Sınıflarına Göre Durum

Kan Basıncı Kategorisi (Diyastolik)	Toplam Birey	Diyabet Pozitif (1)	Diyabet Oranı
Düşük / Normal (< 80)	563	171	%30.4
Hipertansiyon Evre 1 (80-89)	145	65	%44.8
Hipertansiyon Evre 2 (>= 90)	60	32	%53.3

Tablo 7 Analizi: Diyastolik kan basıncı ile diyabet riski arasındaki ilişki, metabolik sendromun komorbidite (eşlik eden hastalık) doğasını doğrulamaktadır. Normal tansiyona sahip bireylerde diyabet oranı %30.4 seviyesindeyken, Hipertansiyon Evre 2 (≥ 90 mm Hg) hastalarında bu oran %53.3'e çıkmaktadır. Kan basıncı yüksekliği diyabetin doğrudan bir sebebi olmasa da, damar çeperi harabiyeti ve insülin direncinin yarattığı kardiyovasküler yükün kronik hastalıklarla eş zamanlı olarak paralel bir seyir izlediğini doğrulamaktadır.

Tablo 8: Cilt Kalınlığı ve İnsülin Dağılım Sınıfları

İnsülin Değeri Segmenti	Ortalama Cilt Kalınlığı (mm)	Diyabet Oranı
Düşük / Normal (< 160)	19.8 mm	%31.2
Yüksek (>= 160)	31.4 mm	%51.6

Tablo 8 Analizi: Bu tablo, vücuttaki periferik yağ dokusu kalınlığı ("SkinThickness") ile serum insülin seviyesi arasındaki doğrudan patofizyolojik ilişkiyi yansıtmaktadır. Yüksek insülin segmentine (≥ 160 µU/ml) sahip olan bireylerin ortalama cilt kalınlığı 31.4 mm olarak ölçülmüştür ve bu gruptaki diyabet prevalansı %51.6'dır. Subkutan yağ dokusundaki artış (obezite göstergesi), insülin reseptörlerinin duyarlılığını azaltarak insülin direncine yol açmakta; bu da kanda daha fazla insülin birikmesine ve nihayetinde diyabet gelişimine zemin hazırlamaktadır.

Tablo 9: Vücut Kitle İndeksi (BMI) Gruplarına Göre Risk

BMI Kategorisi	Aralık	Toplam Birey	Diyabet Oranı
Normal / Zayıf	< 25	117	%6.8
Fazla Kilolu	25 - 29.9	179	%22.3
Obezite Evre 1	30 - 34.9	235	%36.2
İleri Derece Obezite	>= 35	237	%51.9

Tablo 9 Analizi: Vücut Kitle İndeksi (BMI) verileri, kilo kontrolü ve obezitenin diyabet üzerindeki katalizör (hızlandırıcı) rolünü açıkça sergilemektedir. BMI değeri 25'in altında olan (normal/zayıf) kadınlarda diyabet görülme sıklığı sadece %6.8 gibi çok düşük bir düzeydedir. Ancak kilo skalası yukarı doğru tırmadıkça risk oranları sistematik olarak katlanmaktadır: Fazla kilolularda %22.3, Evre 1 obezlerde %36.2 ve BMI değeri 35 ve üzerinde olan ileri derece obez grupta %51.9. Bu bulgu, obezite ile tip-2 diyabet arasındaki doğrusal tetikleme mekanizmasının en net kantitatif kanıtıdır.

Tablo 10: Diyabet Soyağacı Fonksiyonu (DPF) Etki Skoru

Genetik Skor Aralığı (DPF)	Aile Geçmiş Riski	Toplam Birey	Diyabet Oranı
< 0.5	Düşük Kalıtım Riski	494	%29.8
0.5 - 1.0	Orta Kalıtım Riski	211	%41.2
> 1.0	Yüksek Kalıtım Riski	63	%54.0

Tablo 10 Analizi: Diabetes Pedigree Function (DPF), bireyin aile geçmişindeki diyabet vakalarını ve kalıtsal aktarım derecesini skorlayan önemli bir matematiksel modeldir. Genetik geçiş riski skoru 0.5'in altında olan geniş kitlede hastalık oranı %29.8 iken, kalıtım skoru 1.0'in üzerine çıkan yüksek riskli grupta bu oran %54.0'e ulaşmaktadır. Bu durum, kişinin beslenme ve yaşam tarzı gibi çevresel faktörleri optimize edilse dahi, güçlü bir genetik arka planın hastalığı tek başına tetikleme potansiyelinin ne kadar yüksek olduğunu göstermektedir.

Tablo 11: Yaş Gruplarına Göre Diyabet Dağılımı

Yaş Grubu	Toplam Birey	Diyabet Pozitif (1)	Diyabet Sıklığı (Prevalans)
21 - 30 Yaş	417	90	%21.6
31 - 45 Yaş	219	114	%52.1
46 ve Üzeri	132	64	%48.5

Tablo 11 Analizi: Yaş kırılımına göre yapılan prevalans analizi, diyabet riskinin doğrusal sürekli yükselen bir grafik çizmediğini, aksine 31-45 yaş aralığında %52.1 ile tepe noktasına (zirveye) ulaştığını göstermektedir. 46 yaş ve üzeri grupta oran hafif bir düşüşle %48.5'e gerilese de yüksek seyrini korumaktadır. 21-30 yaş arasındaki genç nüfustaki %21.6'lık oran ise küçümsenemeyecek bir seviyede olup, hastalık yaşının aşağı çekildiğinin ve erken yaşlarda klinik tarama programlarının başlatılması gerektiğinin analitik bir göstergesidir.

Tablo 12: Hedef Değişken (Outcome) Sınıf Dengesi Tablosu

Sınıf Etiket (Outcome)	Hasta Durumu	Kayıt Sayısı	Yüzdesel Dağılım
0	Diyabet Negatif (Sağlıklı)	500	%65.1
1	Diyabet Pozitif (Hasta)	268	%34.9

Tablo 12 Analizi: Sınıf dağılım tablosu, makine öğrenmesi ve veri madenciliği süreçlerinin en temel problemi olan veri dengesizliği (class imbalance) durumunu ortaya koymaktadır. Toplam 768 kaydın %65.1'i sağlıklı bireylerden, %34.9'u ise diyabet hastalarından oluşmaktadır. Bu yaklaşık 2:1 oranındaki dengesizlik, ilerleyen aşamalarda veri setini eğitecek modellerin yanlılık (bias) göstermemesi adına salt doğruluk (Accuracy) metriği yerine F1-Skoru ve Hassasiyet/Duyarlılık dengelerine odaklanılması gerektiğini, veri ön işleme aşamasında ise bu dengesizliğin göz önünde bulundurulduğunu hatırlatmaktadır.

Tablo 13: Veri Ön İşleme Sonrası Öznitelik Değişim Özeti

Öznitelik	Ham Veri Durumu	Uygulanan Ön İşleme	Temizlenmiş Veri Dağılım Kararlılığı
Eksik Değerler	Glikoz, BMI ve Tansiyonda sıfırlar mevcut	Medyan ile dolduruldu	Kararlı ve eksiksiz hale getirildi
Uç Değerler (Outliers)	İnsülinde aşırı yüksek değerler var	Logaritmik dönüşüm / Baskılama	Varyans dalgalanması azaltıldı
Ölçekleme	Farklı ölçüm birimleri mevcut	Standartlaştırma (Z-score)	Tüm öznitelikler aynı ölçeğe getirildi

Tablo 13 Analizi: Son aşamada gerçekleştirilen veri ön işleme, PartyRock veri analiz motorunun ve analitik süreçlerin sağlıklı kararlar üretebilmesini sağlayan en köşe taşı adımdır. Tablo 3'te saptanan hatalı sıfır değerleri popülasyon medyanları ile doldurulmuş, Tablo 2'de saptanan insülin ve cilt kalınlığındaki aşırı uç değerler (outliers) logaritmik varyans baskılama yöntemleriyle normalize edilmiştir. Son olarak, tüm değişkenlerin birim uyumsuzluklarını gidermek amacıyla Z-score normalizasyonu uygulanarak veri seti analitik açıdan pürüzsüz hale getirilmiştir.

14. Sorumlu Yapay Zeka ve Veri Adaleti Prensipleri (Responsible AI)

AWS AI & ML Scholars programının temel akademik öğretileri doğrultusunda, Pima Indians Diabetes veri analizi çalışması sadece temel istatistiksel çıktılarla sınırlı kalmamış, aynı zamanda Sorumlu Yapay Zeka (Responsible AI) perspektifinden de teorik olarak değerlendirilmiştir. Biyomedikal ve sosyo-demografik veri setlerinde sıklıkla rastlanan sistematik önyargıların (data bias) veri analizi sonuçlarını doğrudan etkilediği bilinmektedir.

Veri setinde özellikle Tablo 11'de görülen yaş grupları arasındaki hacimsel dengesizlik (21-30 yaş arası 417 birey bulunurken, 46 yaş üstü sadece 132 birey bulunması), veri tabanlı analiz çıktılarının genç popülasyon kalıplarına göre şekillenmesine ve yaşa bağlı bir önyargı (age bias) riski oluşmasına zemin hazırlamaktadır. Sorumlu yapay zeka adalet (fairness) kriterleri uyarınca, veri analiz süreçlerinin tüm alt demografik grupları eşit derecede temsil edebilmesi ve adil sonuçlar yansıtabilmesi büyük önem taşımaktadır. Bu doğrultuda, PartyRock Data Analysis motoru üzerinde çalışırken veri kümesindeki bu hacimsel dengesizliklerin ve potansiyel veri önyargılarının (bias) varlığı analitik olarak göz önünde bulundurulmuş ve değerlendirmeler bu hassasiyetle raporlanmıştır.